

R RAPPORT in1

Syfte

Vilka faktorer är mest kopplade till priset hos försäkringar? En undersökning görs i *R* med ett dataset som först behövs förstås och anpassas, varefter tabeller och grafer ger bild av kostnad emellan grupper. Vidare regressionsmodellering av kostnad kan framhäva inflytande av övriga faktorer relaterade till kundinfo, livsstruktur och hälsa. Därigenom kan rimlighet i vidare prissättningar uppskattas för att vara fungerande stöd till affärsbeslut.

Metod

Datainläsning och anpassning:

Tidyverse läses in och *read_csv* sätter *NA* vid blanka värden. Variabler som passar i heltalsform (t.ex. kund-id och ålder) sätts som integer. Sen görs standardisering (trim, lower och title) på textkolumner, och översättning till logisk från ja/nej kolumnerna. Imputering med median görs i bmi och årliga kontroller, *unknown* för träningsnivå. Nya variabler bmi-klass, historik-score, risknivå, åldergrupp och träning-samt-kontroller skapas, sen körs en funktion som gör kategoriska till factor. Att gruppera åldersspann åt en regressionsmodell kan uppdaga om vissa profiler ska ha prisskillnad, eller om modellen ökar eller tappar prestanda.

Statistiska sammanfattningar:

Pipe %>% gör steg tydliga lager för lager. En *group_by* och sen *summarise* tar fram tabeller som även kan göras plots på (med *ggplot*, *aes* och *labs*). *Mutate*, *arrange* och *select* är pipes för vidare design (ex.vis proportion mellan grupper). Det fokuseras på betalning bland åldersgrupper, bmi, rökning samt rökare och kroniska. Stapelgrafer av betalning från grupperna ålder, bmi och rökare samt kroniska lät visualisera tabellerna.

Regressionsanalys:

Inled med t-test för att se om rökare, kroniska och träning-och-checkups är signifikanta mot pris, där *p*-värde och konfidensintervall ger trolighet och magnitud, respektivt. Detta blir ett isolerat prov av vilka variabler som påverkar pris mest och ifall de bör tas med i regression.

Låt charges vara target i regressionen, och skapa två modeller med olika valda prediktorer; första med ålder, bmi, rökare, kronisk, och den andra med skapade grupper samt *plan_type* (ej *risk_level* för undvika multikolineäritet). Förklaringsgrad och koefficienter jämförs, så att överväganden omkring gitlighet och begränsningar får följa.

Gitlighet överskådas m.hj.a. residualanalys och faktiska mot predikerade priser. Hur fördelning omkring rät linje med lutning 1, och 0 för residualer, tyds modellkvalitet och *QQplot* visar hur normalfördelade residualer är.

Resultat

Statistiska sammanfattningar signalerade positiva samband mellan prediktorer och target via skillnader emellan grupper, som kontrolleras ifall de speglas i regressionen. I tabellerna var tendenserna ökande kostnader mot högre bmi-klasser, såväl som rökare och kroniskt drabbade, med mindre standardfel bland rökare än bmi. Då juniorer t.o.m. medelålders

människor inte hade mycket större kostnader, kan skillnaderna förklaras av andra faktorer såsom rökare och kroniska bland de åldersklasserna. Nu följer resultat från t-test, sen redogörs om regression bekräftar den positiva korrelationen eller expanderar med insikter.

Variabel	t-värde	95% CI	Effekt
smoker	-27.7	(-8514, -7387)	Rökare betalar mer
chronic_condition	-15.5	(-5231, -4057)	Kroniskt drabbade betalar mer
exercises_checks	-4.8	(-2141, -893)	Mindre hälsosamma betalar mer
risk_level	24.1	(4801, 5654)	Högrisk kunder betalar mer

Tabell 1: t-test av variabler.

Inledande t-test visar att rökare och kroniskt drabbade betalar mer, med olika magnituder 95% konfidensintervall. Variablerna bedöms viktiga till pris, medan hälsovanor hade mindre skillnad än övriga, hade de alla signifikans med $p < 0.001$.

Regressionsanalys

Modell ett och två har skapats olika; deras koefficienter och innebörd följer, med R signifikanskoder: 0 '***', 0.001 '**', 0.01 '*', 0.05 '.', 0.1 ' ', 1.

Modell 1:

Variabel och p	Koefficient, Kr	Effekt
Intercept	-129	Om prediktorer = 0
age ***	76	Ökning / år
bmi ***	165	Ökning / enhet
smoker ***	7747	Ökning för rökare
chronic_condition ***	4101	Ökn för kroniska

Modell 2:

Variabel och p	Koefficient, Kr	Effekt
Intercept ***	5875	Om prediktorer = första level
Middle Age **	1894	Ökn från junior
Senior ***	3706	Ökn från junior
Young Adult ' '	557	Ej signifikant
Obese **	1193	Ökn från normal
Overweight ' '	274	Ökning från normal
Underweight .	-653	Minskn från normal
Premium ***	1935	Ökning från basic
Standard ***	1018	Ökning från basic
Historic_score ***	1467	Ökning / enhet
Less Healthy **	1073	Ökn från healthy

Förklarad varians och residual *std*:

- Modell 1: 69%, 2550.
- Modell 2: 16.9%, 4171.

Tabell 2 & 3: koefficienternas värden.

Modell 1 har 69% förklarad varians när den uppskattar pris, och modell 2 16.9%. Residualfel är 2550, lägre än andra modellens 4171. Intercept är när alla inputs är första *level*, som är junior och normal bmi klassen. Första modellens intercept är insignifikant, men den andra är.

I övergången från bmi och ålder som heltal i modell 1 till grupper i modell 2 görs avgörande beslut vart de avgänsningarna sätts, något som påverkar koefficienterna i hur gradvisa de är. Mindre gradvisitet i modell 2 håller exempelvis en kostnad på 557 kronor att gå från junior till ung vuxen (allt annat lika).

Rökning är den dyraste kategorin att övergå till med 7747 kronor enligt modell 1. När *plan_type* inkluderas i Modell 2 ökade justerad R^2 med 2% till 16.9%, som gör modellen mer affärsnära och visar på att den variabeln påverkar pris mindre än rökning, varvid justerad R^2 skulle straffa inklusionen av ännu en variabel ifall den inte hade förklaring mot pris.

Felanalys

Scatterplot med en 1:1 linje visade för modell 1 mest jämnt spritt kluster i över- och underpredikeringar. Modell 2 hade större kluster under samma linje, med några mindre täta och längre överskattade punkter. Residualer har i scatterplot med $h=0$ linje motsvarande modellbeteenden; tydligare obalans för modell 2. *QQplot* visar stabilitet i modell 1, dock en höger svans med överestimat, medan modell 2 är ovanför, även vid täta punkter nära mitten, och under vid mitten.

Modellernas olikheter:

Fördelar med att ha mer korrekta prediktionsvärden som med modell 1 vägs av mot nackdelar att inte ha tillgängliga tolkningar för handläggare eller modellenpassning. De 69% förklarad varians grundas i att rökstatus, kroniska, ålder och bmi blev inräknade (varav de två senare mer detaljerat och ogrupperat). Andra modellens lägre förklarad varians på 16.9% berättar att data förloras vid förenklingar till grupper. Även är R^2 såpass lägre p.g.a. att kroniska, rökare och *risk_level* uteslöts, medan vi vet från t-test och regression att de är högt bidragande faktorer till pris.

Ett sätt att balansera ut de olika R^2 är att flytta inklusion av kroniska till modell 2. Även är det aktuellt att göra en tredje modell som testar *risk_level* för att se om en sådan kategori skiljer sig i prestanda från de individuella variablerna rökare, kroniska och historikscore. Där gäller avgränsningspåverkan också, medan multikoliniariteten bör fortsättas undvikas; om en variabel är inräknad flera gånger i samma modell kan resultaten skeva. Hur högt R^2 kan nå i en modell är inte utrett, men överanpassning är en risk för instabilitet i prediktioner på ny data.

Slutsatser

Regression och t-test har uppdagat kritiska faktorer som driver försäkringspriser, stämmande mot sammanfattningarna. Rökning är den enskilt största kostnadsdrivaren, ett livsstilsval som enligt regression ökar priset med 7747 kr. Kroniska tillstånd har näst störst ökning, följt av att gå från junior till senior som dock går genom ung vuxen, medelålders först. Ålder och bmi berör demografi, där senior och fetma är mest kostsamma övergångarna; och även som numeriska är de kärnvariabler. Historikscore är statistiskt signifikant och borde såsom plantyp tas med vid prissättning.

Hur data är inräknat i modellerna, som vid ålder och bmi kategoriskt, framhävde avvägning såsom sämre gradvisitet mot ökad förklarbarhet hos handläggare eller modellenpassning. Numerisk modell förklarade 69% av varians i pris, men har inte kategoriskt stöd för handläggare att kundsegmentera eller ekonomi-team att sätta priser till. Det följer att om en precis modell sätter priser, och en lättare förklarad modell hjälper vid segmentering och sälj, kan konflikt mellan användning och precision avstyras.

Felanalys stödjer att modell 1 predikerar med mindre systemiska fel än modell 2, och färre outliers.

Begränsningar

Giltighet påverkas av:

Dataset: prisernas verklighet är inte fullt speglad av datasetets finita variabler. Människor har olika geografiska, genetiska och arbetslivs-risker, så hälsotfaktorer kan expanderas till datan för att nå mer verklighetstroga förhållanden.

Imputering: insättande av median är robust för outliers, men att ha ett komplett dataset (bmi, årliga kontroller) undgår viss förlust av sambandsdynamik.

Modellen: om linjär regression är mest passande för prediktioner är inte klargjort, så mer komplexa prismönster missas; till exempel eventuell exponentiell prisökning för hög ålder eller bmi. Även är kausalitet inte redogjort från modelleringen, vilket gör att resultat ska tas som uppskattning, inte fakta.

Analysen: resultat varierar med prediktorer, varav prov av *risk_level* och andra avgränsningar erhåller flera prestationer att göra jämförelser med. Påverkan av R^2 via dataset och modell, multikolinearitet och överanpassning åsido, visar kompromissen precision mot tolkbarhet.

Självreflektion

Från att bearbeta data och göra relevanta variabler, sammanfattningar, visualer och regression- samt felanalys med *R*, har försäkringspriser i affärssammanhang anknutits till hälsa, tobak, historik och försäkringsplan med rimlighet emot människans vardag.

Det som gick bra är att två modeller i regression ledde till insikt i att kategoriseringar får precision att gå förlorad, och kategorier medför enklare användning. Kritiska prediktorer sågs förklara pris mer än försäkringsplan, men att hålla modeller verklighetsnära följer kännedom om människan och affärsvärlden. Beaktningar gjordes runtom multikolinearitet, för högt R^2 och begränsningar inför kausalitet-fastställande. Bekräftelser för regressionens resultat syntes i felanalysen.

Motstånd i projektet möttes med att modeller kan designas på många kombinerade sätt, mellan kategorier och numeriska, vilket utökar mängden resultat att dra insikter ifrån.

Kraven mot att fördjupa jämföra modeller, följa kritisk metodik och koppla statistik till affärsvärlden anser jag väl genomförda.