

Martin_W_InsuranceWithR

AUTHOR

Martin Westberg

1. Dataförståelse

Läs in data:

```
# message och warning=FALSE, så undviks output av följande:
library(tidyverse)
df <- read_csv("insurance_costs.csv")
```

```
glimpse(df)
```

Rows: 1,100

Columns: 14

```
$ customer_id    <chr> "C100000", "C100001", "C100002", "C100003", "C100004..."
$ age            <dbl> 48, 40, 50, 62, 39, 39, 63, 52, 36, 49, 36, 36, 45, ...
$ sex            <chr> "female", "male", "female", "male", "female", "femal..."
$ region         <chr> "east", "west", "south", "north", "east", "west", "e..."
$ bmi            <dbl> 24.8, 29.5, 18.3, 25.5, 27.3, 23.3, 23.9, 24.8, 28.6...
$ children       <dbl> 0, 1, 2, 5, 2, 4, 3, 2, 0, 2, 2, 2, 1, 1, 1, 1, 0, 3...
$ smoker         <chr> "no", "no", "no", "yes", "no", "no", "no", "no", "no..."
$ chronic_condition <chr> "no", "no", "no", "no", "no", "no", "no", "no", "yes..."
$ exercise_level <chr> "high", "medium", "high", "medium", "medium", "high"...
$ plan_type      <chr> "basic", "basic", "standard", "basic", "basic", "sta..."
$ prior_accidents <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 1, 0, 0, 0, 0, 0...
$ prior_claims   <dbl> 0, 1, 0, 0, 1, 0, 0, 0, 1, 0, 0, 1, 0, 1, 3, 0, 0...
$ annual_checkups <dbl> 1, 4, 3, NA, 0, 2, 1, 2, 3, 2, 3, 3, 4, 4, 2, 1, 2, ...
$ charges        <dbl> 6439.10, 8274.06, 5190.99, 14500.35, 6534.40, 8026.3...
```

Det är 1,100 observationer med 14 variabler, och datatyperna ska justeras:

- heltal, decimaltal, booleans och strängar.
- det kan behövas filtrering eller ifyllnad, samt trim, lower, och title.

Se närmare på kolumner med saknade värden:

```
# Antal NA per kolumn:
# colSums(is.na(df_clean))
#      anger att: bmi, exercise_level, annual_checkups har NaN.

# Se över unique values i olika kolumner:
# unique(df$exercise_level)
unique(df$plan_type)
```

```
[1] "basic"      "standard" "premium"  "Premium"  "Standard"
```

2. Datastädning och förberedelse

Åtgärder i städning:

- Kundnummer görs till heltal genom att först ta bort "C".
- Vid NaN: BMI och årliga besök får median insatt, och träningsnivå får **unknown**.
- Gör "Ja/Nej" till logisk.

```
source("script1_cleaning.R")
```

Nya variabler och konvertera *chr* till *fct*:

- Skapa kolumner med *if_else* och *case_when* som följer kriterier, så fås olika grupper. Även **historic_score** via addition av tidigare olyckor samt fordringar.
- Det görs även en lista med kategoriska kolumner (som är städade redan), sen en funktion som sätter *as.factor*, sen kallas den och skriver över resultatet till **df_clean**.

```
# Summary visar vanliga värden, så kan man välja numeriska gränser i kategori variabler.
# summary(df_clean$bmi)
source("script2_createVar_andFactor.R")
glimpse(df_clean)
```

Rows: 1,100

Columns: 19

```
$ customer_id    <int> 100000, 100001, 100002, 100003, 100004, 100005, 1000...
$ age            <int> 48, 40, 50, 62, 39, 39, 63, 52, 36, 49, 36, 36, 45, ...
$ sex            <fct> female, male, female, male, female, female, female, ...
$ region         <fct> East, West, South, North, East, West, East, North, E...
$ bmi            <dbl> 24.8, 29.5, 18.3, 25.5, 27.3, 23.3, 23.9, 24.8, 28.6...
$ children       <int> 0, 1, 2, 5, 2, 4, 3, 2, 0, 2, 2, 2, 1, 1, 1, 1, 0, 3...
$ smoker         <lgl> FALSE, FALSE, FALSE, TRUE, FALSE, FALSE, FALSE, FALS...
$ chronic_condition <lgl> FALSE, FALSE, FALSE, FALSE, FALSE, FALSE, FALSE, FALS...
$ exercise_level <fct> High, Medium, High, Medium, Medium, High, High, Medi...
$ plan_type      <fct> Basic, Basic, Standard, Basic, Basic, Standard, Basi...
$ prior_accidents <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 1, 0, 0, 0, 0, 0, 0...
$ prior_claims   <int> 0, 1, 0, 0, 1, 0, 0, 0, 1, 0, 0, 1, 0, 1, 3, 0, 0, 0...
$ annual_checkups <int> 1, 4, 3, 2, 0, 2, 1, 2, 3, 2, 3, 3, 4, 4, 2, 1, 2, 1...
$ charges        <dbl> 6439.10, 8274.06, 5190.99, 14500.35, 6534.40, 8026.3...
$ bmi_class      <fct> Normal, Overweight, Underweight, Normal, Overweight,...
$ historic_score <int> 0, 1, 0, 0, 1, 0, 0, 0, 1, 1, 0, 2, 0, 1, 3, 0, 0, 0...
$ risk_level     <fct> Low, Low, Low, High, Low, Low, Low, Low, High, High,...
$ age_group      <fct> Middle Age, Young Adult, Middle Age, Senior, Young A...
$ exercises_checks <fct> Healthy, Less Healthy, Healthy, Less Healthy, Less H...
```

Nu har vi factor som datatyp för kategorier, så *dplyr* hanterar grupperingar väl.

De nya variablerna **bmi_class**, **historic_score**, **risk_level**, **age_group**, **exercise_checks** ger regressionsmodellering yta att undersöka om olika profiler är kopplade till större betalning.

3. Beskrivande analys

3.1 Betalning bland åldergrupper

```
# Ladda script 3 och visa output för åldergrupper
source("script3_descriptive_analysis.R")
age_grouped # stigande ordning: medelvärde.
```

```
# A tibble: 4 × 5
  age_group mean_charge median_charge n proportion_pct
  <fct>      <dbl>      <dbl> <int>      <dbl>
1 Junior      8337.      7884.   44         4
2 Young Adult  9076.      8103.  432        39.3
3 Middle Age  10550.     9758.  527        47.9
4 Senior     12566.    11166.   97         8.8
```

De flesta är inte äldre än 60 eller yngre än 20. Även syns att betalningar ökar i snitt och median med ålder.

3.2 Betalning bland bmi-kategori

```
bmi_grouped # stigande (mean)
```

```
# A tibble: 4 × 5
  bmi_class mean_charge median_charge std_charge proportion_pct
  <fct>      <dbl>      <dbl>      <dbl>      <dbl>
1 Underweight  9171.      8286.      4427.      22.9
2 Normal      9854.      8896.      4484.      22.6
3 Overweight  10139.     9168.      4337.      29.9
4 Obese      10985.     9910.      4907.      24.5
```

De med mer än 30.5 och mindre än 16 i bmi betalar mer och mindre, respektivt, än normal- och överviktiga. En föraning är att kostnader har större skillnader för de två mitten bmi-klasserna (och ålder) med ursprung i andra led. Övergripande stiger kostnader med bmi-klass.

3.3 Betalning inom rökning

```
smoker_grouped # fallande (mean)
```

```
# A tibble: 2 × 4
  smoker mean_charge median_charge proportion_pct
  <lgl>      <dbl>      <dbl>      <dbl>
1 TRUE      16537.      16392.      18.5
2 FALSE      8586.       8232.      81.5
```

Rökare betalar det dubbla, medan de motsvarar 18.5%.

3.4 Betalning bland rökare och kroniska

```
smoker_chronic # fallande (proportion)
```


```
# A tibble: 4 × 6
  smoker chronic_condition mean_charge median_charge std_charge proportion_pct
  <lgl> <lgl>      <dbl>      <dbl>      <dbl>      <dbl>
1 TRUE  TRUE      16537.      16392.      4427.      18.5
2 TRUE  FALSE      8586.       8232.      4484.      81.5
3 FALSE TRUE      10139.     9168.      4337.      29.9
4 FALSE FALSE     9854.     8896.      4484.      22.6
```

1	FALSE	FALSE	7554.	7467.	2569.	62.5
2	FALSE	TRUE	11978.	11871.	3046.	19
3	TRUE	FALSE	15444.	14652.	3411.	13.2
4	TRUE	TRUE	19224.	18883.	3282.	5.4

Medan nästan 63% varken är kroniska eller rökare, indikeras stigande kostnader (medel) för drabbade från cirka 7500 till 19200.


3.5 Visualer

```
source("script4_visuals.R")  
# åldersgrupp col plot  
ageplot
```




Betalning tycks öka med åldersgrupp, särskilt när senior.

```
# bmi-klasser col plot  
bmipLOT
```



Betalning tycks öka med bmi-klass, men de två i mitten betalar nästan lika.

```
# true/false col plot  
smoke_chron_plot
```



Bland rökare, betalar kroniska mera, samma gäller icke-rökare. Samtidigt är rökande status led till högre betalning också. Är profilen ej rökande eller kronisk så betalar denna ungefär hälften eller en tredjedel av de andra profilerna.

I helhet tycks ålder eller vikt inte driva skillnader i betalning mest, utan övriga faktorer såsom rökare och kroniska, där differenser i pris är framstående. Vad som antyds är att rökning är en kritisk risk som bör rättfärdiga en högre försäkringskostnad. Rökning och övriga faktorer går igenom i regressionsanalysen.

4. Regressionsanalys

Vilka features som leder mest till prissättningarna ska nu fokuseras på. I initiell analys syntes liknelser och skillnader emellan profiler, men helheten i sambanden är inte klarlagt. Är det så att risker går upp i steg som från vuxen till senior, eller numeriskt (kontinuerligt); jämförelse av olik designade regressionsmodeller följer, efter ett inledande hypotestest.

4.1 Hypotestest

Om binära och numeriska variabler har stor påverkan på pris var för sig, så kan p-värde och konfidensintervall indikera viktigheten i tvåsticksprov Welch t-test. ANOVA hanterar ickebinära och görs inte i detta arbetet. T-testets isolerande prövning blir uppföljt av multipel regression efteråt vilket fångar variablernas samspel.

```
# Välj rökare, kroniska, hälsovanor och risknivå-variablerna, då de kan vara hälsokritiska.  
  
t_test_smoker <- t.test(charges ~ smoker, data = df_clean)
```

```
t_test_chronic <- t.test(charges ~ chronic_condition, data = df_clean)
t_test_exerciseschecks <- t.test(charges ~ exercises_checks, data = df_clean)
t_test_risklevel <- t.test(charges ~ risk_level, data = df_clean)

t_test_smoker
```

Welch Two Sample t-test

data: charges by smoker

t = -27.771, df = 276.46, p-value < 2.2e-16

alternative hypothesis: true difference in means between group FALSE and group TRUE is not equal to 0

95 percent confidence interval:

-8514.891 -7387.624

sample estimates:

mean in group FALSE	mean in group TRUE
8585.889	16537.147

```
# t_test_chronic
# t_test_exerciseschecks
# t_test_risklevel
```

t-test resultat:

Variabel	t-värde	95% konfidensintervall	Effekt
smoker	-27.7	(-8514, -7387)	Rökare betalar mer
chronic_condition	-15.5	(-5231, -4057)	Kroniskt drabbade betalar mer
exercises_checks	-4.8	(-2141, -893)	Mindre hälsosamma betalar mer
risk_level	24.1	(4801, 5654)	Högrisk kunder betalar mer

Notera att ordningen på true och false orsakar minustecknet, medan effekten beskriver ordningen. Siffran noll var inte med i konfidensintervallen, och så var $p < 0.001$ i alla granskningar; statistiskt signifikant.

Framträdelsevis är **smoker** den status som leder till störst betalningsskillnad, sett i magnituden av intervallet. Sen följer av kronisk, risknivå (vilken består av bl.a. rökare och kronisk) och sist hälsovanor. Hälsovanor kan tolkas vara kompletterande för hälsan, medan status av rökning och kronisk har större avgörande (och därmed borde tas med i regressionen).

4.2 Modellering

Vi gör två modeller (en med originella variabler och en med anpassade) och undersöker resultaten om pris följer räta förhållanden. Variabeln **risk_level** är gjord med bmi, rök- och kronisk-status, så den tas

inte med för multikolineäritet riskerar skeva resultaten.

```
# Modell 1, med age, bmi, smoker och kronisk.
modell1 <- lm(charges ~ age + bmi + smoker + chronic_condition, data = df_clean)
summary(modell1)
```

Call:

```
lm(formula = charges ~ age + bmi + smoker + chronic_condition,
    data = df_clean)
```

Residuals:

Min	1Q	Median	3Q	Max
-10052.0	-1649.1	-117.3	1571.5	17803.5

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-129.059	533.197	-0.242	0.809
age	75.919	6.254	12.140	<2e-16 ***
bmi	164.978	17.013	9.697	<2e-16 ***
smokerTRUE	7747.191	198.193	39.089	<2e-16 ***
chronic_conditionTRUE	4100.990	180.041	22.778	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2550 on 1095 degrees of freedom

Multiple R-squared: 0.6904, Adjusted R-squared: 0.6893

F-statistic: 610.5 on 4 and 1095 DF, p-value: < 2.2e-16

Modell 1 har R^2 á 69%, $p < 0.001$, och residual standardfel: 2550. De fyra koefficienterna har $p < 0.001$.

En negativ intercept när features antas vara noll (modell 1) beror på matematik, och basvärdet för kategorier är antagna.

```
# Modell 2, med skapta variabler (ej risk_level)
modell2 <- lm(charges ~ age_group + bmi_class + plan_type +
              historic_score + exercises_checks, data = df_clean)
summary(modell2)
```

Call:

```
lm(formula = charges ~ age_group + bmi_class + plan_type + historic_score +
    exercises_checks, data = df_clean)
```

Residuals:

Min	1Q	Median	3Q	Max
-10149.2	-2899.2	-992.8	2232.7	22841.2

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5875.3	746.9	7.866	8.79e-15 ***
age_groupMiddle Age	1894.3	657.6	2.881	0.004046 **
age_groupSenior	3706.2	761.1	4.870	1.28e-06 ***


```

age_groupYoung Adult          557.9      662.8    0.842 0.400129
bmi_classObese                1193.2      368.6    3.237 0.001245 **
bmi_classOverweight           274.8      352.4    0.780 0.435738
bmi_classUnderweight          -653.5      375.7   -1.740 0.082229 .
plan_typePremium              1935.7      369.9    5.232 2.01e-07 ***
plan_typeStandard             1018.2      288.4    3.530 0.000433 ***
historic_score                 1467.1      158.0    9.288 < 2e-16 ***
exercises_checksLess Healthy  1073.5      330.0    3.253 0.001176 **

```

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Residual standard error: 4171 on 1089 degrees of freedom

Multiple R-squared: 0.1764, Adjusted R-squared: 0.1688

F-statistic: 23.32 on 10 and 1089 DF, p-value: < 2.2e-16

```
levels(df_clean$age_group) # första värdet är referenspunkten för koefficienter.
```

```
[1] "Junior"      "Middle Age"  "Senior"     "Young Adult"
```

```
levels(df_clean$bmi_class) # referenspunkterna: normal bmi, junior åldersgrupp.
```

```
[1] "Normal"      "Obese"       "Overweight"  "Underweight"
```

Modell 2 har lägre R^2 å 16.9%, $p < 0.001$, och högre residual standardfel: 4171, sämre predikerandes. Senior, intercept, historik, premium samt standard plan har $p < 0.001$. Senior har 3908 kr ökning ifrån Junior.

Mindre förklarad varians hos den andra modellen föreslår att kategoriserande får precision att tappa, medan förklarbarhet med kategorier ökar i affärsnära nyttjande (och betalningsplan har i verklighet prisskillnader). Hur gränserna är dragna vid kategoriskapandet är avgörande, de var improviserade och osannolikt optimala, vilket regressionen framhäver. Segment kan bära fördel i affärsliv, men dessa kontinuerliga variabler ledde inte till en mer precis statistisk modell.

4.3 Felanalys


```

# Gör regressions- och residualgrafer
source("script5_regression.R")

# 2 modellers faktiska och predikerade priser
regplot

```


Faktiska och predikerade priser, båda modeller



Modell 1 visar mer närhet till *1:1 linjen*, medan modell 2 har större kluster under linjen.

```
# Residualgraf  
errplot
```


Residualer i enkel och mer avancerad modell



Residualer ligger balanserat över och under 0-linjen för modell 1, medan modell 2 har större spridning av fel och kluster under linjen.

```
# QQplot modell 1
qqnorm(resid(modell1))
qqline(resid(modell1), col = "red")
```


Normal Q-Q Plot



Första modellen har punkter nära referenslinjen för mestadelen, med lite flera uppgående outliers i höger.

```
# QQplot modell 2  
qqnorm(resid(model2))  
qqline(resid(model2), col = "red")
```

Normal Q-Q Plot



Andra modellen avviker mer från normalfördelning till vänster och höger med synlig skevhet.